

Instituto de Ensino Superior ICEV
Pós-graduação em Inteligência Artificial
Aprendizagem de Máquinas em Séries Temporais

Comparação de Modelos Estatísticos e de Aprendizado de Máquina para Previsão de Séries Temporais

Alunos:

João Pedro Coelho Barbosa
Luis Eduardo Alencar Melo

Professora:

Maria Eva Clemencia Fonseca Castro Silva

Teresina – PI

2026

Sumário

1	Introdução	2
2	Metodologia	2
2.1	Análise Exploratória	2
2.2	Teste de Estacionariedade	4
2.3	Construção de Variáveis Defasadas (<i>Lags</i>)	5
2.4	Divisão Treino/Teste	5
2.5	Modelos Avaliados	6
3	Resultados	7
3.1	Tabela Comparativa de Desempenho	7
3.2	Previsão do Melhor Modelo	7
4	Discussão Técnica	8
4.1	Análise de <i>Overfitting</i>	8
4.2	Capacidade de Capturar Tendência e Sazonalidade	8
4.3	Limitações do Estudo	9
5	Conclusão	9

1 Introdução

A previsão de séries temporais constitui uma das áreas mais relevantes do aprendizado de máquina aplicado, especialmente em domínios onde a evolução temporal dos fenômenos possui implicações diretas para o planejamento estratégico e operacional. No setor elétrico brasileiro, a capacidade de antecipar variações na estrutura do parque gerador é fundamental para subsidiar decisões regulatórias, de expansão de capacidade e de segurança energética.

O presente trabalho utiliza dados públicos disponibilizados pela Agência Nacional de Energia Elétrica (ANEEL), referentes à variação mensal do número de Unidades Geradoras (UGs) em operação no Piauí. A série abrange o período de agosto de 2017 a janeiro de 2026, totalizando 91 observações mensais. Esta base de dados foi obtida diretamente do portal de dados abertos da ANEEL, fonte oficial e reconhecida no setor de regulação energética nacional.

A escolha desta série se justifica por múltiplos critérios. Do ponto de vista técnico, a série apresenta características que desafiam modelos clássicos: tendência de crescimento acelerado, padrão sazonal de periodicidade semestral e episódios de volatilidade crescente ao longo do tempo. Do ponto de vista prático, a expansão contínua da geração distribuída e das fontes renováveis no Brasil torna a previsão desta variável estratégica para o planejamento do sistema elétrico nacional.

O objetivo deste trabalho é implementar e comparar sete modelos de previsão - ARIMA, SARIMA, Árvore de Decisão, Random Forest, XGBoost, MLP e LSTM - sobre esta série temporal, seguindo rigorosamente o pipeline metodológico estabelecido na disciplina. A avaliação é conduzida com base em quatro métricas quantitativas: Erro Médio Absoluto (MAE), Raiz do Erro Quadrático Médio (RMSE), Erro Percentual Absoluto Médio (MAPE) e Coeficiente de Determinação (R^2). Ao final, o modelo com melhor desempenho no conjunto de teste é identificado e analisado criticamente.

2 Metodologia

2.1 Análise Exploratória

A análise exploratória teve como objetivo caracterizar o comportamento da série temporal antes da aplicação dos modelos. A Figura 1 apresenta a evolução mensal das Unidades Geradoras ao longo do período estudado.




Figura 1: Variação mensal das Unidades Geradoras (série completa, 2017–2026).

A inspeção visual evidencia uma tendência de crescimento monotônico, inicialmente suave e progressivamente mais acentuado a partir de 2022, com pico próximo a 10.500 UGs em janeiro de 2026. A série também exibe flutuações periódicas recorrentes, sugestivas de sazonalidade.

Para decompor formalmente estes componentes, aplicou-se a decomposição clássica aditiva, cujos resultados são apresentados na Figura 2.




Figura 2: Decomposição clássica da série: componentes de tendência, sazonalidade e resíduo.

A decomposição confirma a presença de uma tendência crescente de longo prazo e de um padrão sazonal com ciclos aproximados de 6 meses, com picos de amplitude entre -400 e $+700$ unidades. O componente residual, embora predominantemente centrado em

zero, apresenta variância crescente no final do período, refletindo a aceleração da expansão do parque gerador a partir de 2024.

2.2 Teste de Estacionariedade

A estacionariedade da série foi avaliada por meio do Teste de Dickey-Fuller Aumentado (ADF), cujos resultados são apresentados na Tabela 1.

Tabela 1: Resultados do Teste ADF para a série original e sua primeira diferença.

Série	Estatística ADF	p-valor
Original	0,8219	0,9920
1ª Diferença	-1,3592	0,6017

Para a série original, a estatística ADF de 0,8219 com p -valor = 0,9920 indica fortemente a presença de raiz unitária, ou seja, a série não é estacionária. Os valores críticos a 1%, 5% e 10% são, respectivamente, $-3,506$, $-2,895$ e $-2,584$. Após a primeira diferenciação, a estatística $-1,3592$ ($p = 0,6017$) permanece acima dos valores críticos, indicando que a diferenciação simples não foi suficiente para induzir estacionariedade plena. Este comportamento é consistente com uma série de tendência determinística acelerada, cujo componente de crescimento exponencial exige transformação adicional ou modelagem explícita da tendência por meio do componente integrado do modelo SARIMA.

As funções de autocorrelação (ACF) e autocorrelação parcial (PACF), apresentadas nas Figuras 3 e 4, forneceram subsídios adicionais para a identificação das ordens dos modelos estatísticos.




Figura 3: ACF e PACF da série original. O decaimento lento da ACF confirma a não-estacionariedade.




Figura 4: ACF e PACF após a primeira diferenciação. Picos nos lags 12 e 24 sugerem sazonalidade anual.

Na série original, a ACF apresenta decaimento lento e persistente, característico de processo integrado. Após a diferenciação, observam-se picos significativos no lag 12 na ACF e no lag 12 na PACF, corroborando a existência de sazonalidade de período 12 meses identificada na decomposição clássica. Estes padrões orientaram a seleção das ordens dos modelos ARIMA e SARIMA.

2.3 Construção de Variáveis Defasadas (*Lags*)

Para viabilizar a aplicação dos modelos de aprendizado de máquina – que, ao contrário dos modelos ARIMA/SARIMA, não incorporam nativamente a estrutura temporal da série – foi realizada a engenharia de *features* por meio da criação de variáveis defasadas (*lags*). Cada observação no tempo t foi enriquecida com os valores da série nos instantes $t - 1, t - 2, \dots, t - k$, de modo que a informação histórica relevante estivesse disponível como entrada para os modelos.

Com base no diagnóstico de dependência temporal obtido a partir das funções de autocorrelação (ACF) e autocorrelação parcial (PACF), adotou-se $k = 12$ defasagens, incorporando um ciclo completo de periodicidade mensal. Em particular, a presença de picos em torno do *lag* 12 (e seus múltiplos) após a diferenciação reforça a relevância de capturar componentes sazonais anuais, justificando a inclusão das defasagens até $t - 12$.

Após a adição das 12 variáveis defasadas, o conjunto de dados resultante passou a conter 91 linhas e 15 colunas, sendo a variável alvo a observação no instante t e as demais colunas correspondentes aos *lags* e eventuais *features* sazonais derivadas. As primeiras observações, cujos *lags* não estavam disponíveis, foram descartadas, preservando a integridade temporal do conjunto.

2.4 Divisão Treino/Teste

A divisão entre conjuntos de treinamento e teste respeitou estritamente a ordem cronológica dos dados, conforme exigido pelo protocolo metodológico da disciplina. O embaralhamento aleatório das observações foi explicitamente evitado, pois comprometeria a validade da avaliação preditiva em séries temporais.

O conjunto de treinamento foi composto pelos 79 meses mais antigos (com 14 *features* cada), correspondendo ao período de agosto de 2017 a dezembro de 2024. O conjunto

de teste abrangeu os 12 meses mais recentes (janeiro a dezembro de 2025), representando aproximadamente 13% das observações disponíveis. Esta proporção garante que o modelo seja avaliado sobre um horizonte de previsão de um ano completo, período relevante do ponto de vista operacional.

2.5 Modelos Avaliados

Foram implementados e avaliados sete modelos, descritos a seguir.

ARIMA (*Autoregressive Integrated Moving Average*): modelo estatístico clássico parametrizado por (p, d, q) , onde p é a ordem autorregressiva, d o grau de diferenciação e q a ordem da média móvel. A forma geral do modelo é:

$$\phi(B)(1 - B)^d y_t = \theta(B)\varepsilon_t, \quad (1)$$

onde B é o operador de retardo, $\phi(B)$ e $\theta(B)$ são polinômios autorregressivo e de média móvel, respectivamente, e $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$. O melhor ARIMA identificado por busca em grade foi o de ordem $(1, 1, 3)$, com $AIC = 1344,45$.

SARIMA (*Seasonal ARIMA*): extensão do ARIMA que incorpora componentes sazonais $(P, D, Q)_s$, onde s é o período sazonal. O modelo é representado por:

$$\phi(B)\Phi(B^s)(1 - B)^d(1 - B^s)^D y_t = \theta(B)\Theta(B^s)\varepsilon_t. \quad (2)$$

O melhor SARIMA identificado foi o de ordem $(2, 1, 2)(1, 1, 1)_6$, com $AIC = 1040,64$, confirmando a relevância da componente sazonal de período 6 meses.

Árvore de Decisão: modelo não-paramétrico que particiona recursivamente o espaço de *features* em regiões homogêneas, minimizando o erro quadrático médio em cada nó. Embora interpretável, é suscetível a sobreajuste sem poda adequada.

Random Forest: conjunto de árvores de decisão treinadas sobre amostras bootstrap do conjunto de treinamento, com seleção aleatória de *features* em cada divisão. A previsão final é a média das previsões individuais, reduzindo a variância em relação a uma única árvore.

XGBoost (*Extreme Gradient Boosting*): algoritmo de *boosting* que treina árvores de forma sequencial, com cada árvore corrigindo os erros residuais da anterior. Incorpora regularização L_1 e L_2 para controle do sobreajuste.

MLP (*Multilayer Perceptron*): rede neural *feedforward* com camadas ocultas totalmente conectadas e funções de ativação não-lineares. Capaz de aprender representações complexas, mas exige normalização e ajuste cuidadoso de hiperparâmetros.

LSTM (*Long Short-Term Memory*): arquitetura de rede neural recorrente projetada para capturar dependências de longo prazo em sequências temporais. Utiliza mecanismos de *gates* (entrada, esquecimento e saída) para controlar o fluxo de informação ao longo do tempo.

3 Resultados

3.1 Tabela Comparativa de Desempenho

A Tabela 2 apresenta o desempenho de todos os modelos no conjunto de teste, ordenado pelo RMSE crescente.

Tabela 2: Comparação de desempenho dos modelos no conjunto de teste (12 observações).

Modelo	MAE	RMSE	MAPE (%)	R^2
SARIMA	391,59	538,07	5,98	0,8082
XGBoost	570,62	782,60	7,62	0,5943
LSTM	818,04	958,47	11,85	0,3914
MLP	1211,14	1295,52	18,54	-0,1119
Random Forest	1018,51	1551,89	12,68	-0,5954
Decision Tree	1918,67	2023,53	29,17	-1,7125
ARIMA	2970,89	3181,96	46,01	-5,7073

O modelo SARIMA obteve o melhor desempenho em todas as métricas avaliadas, com $RMSE = 538,07$, $MAE = 391,59$, $MAPE = 5,98\%$ e $R^2 = 0,8082$. Estes resultados indicam que o modelo explica aproximadamente 80% da variância da série no período de teste, com erro percentual médio inferior a 6%. O segundo melhor modelo foi o XGBoost, com $RMSE = 782,60$ e $R^2 = 0,5943$, seguido pelo LSTM. Os demais modelos apresentaram R^2 negativos, indicando desempenho inferior ao de uma previsão constante pela média.

3.2 Previsão do Melhor Modelo

A Figura 5 apresenta a comparação entre os valores reais e as previsões do modelo SARIMA(2, 1, 2)(1, 1, 1)₆ na janela de teste (janeiro a dezembro de 2025).




Figura 5: Comparação entre valores reais e previstos pelo SARIMA na janela de teste (2025).

O gráfico evidencia que o SARIMA acompanhou adequadamente o comportamento

geral da série, capturando tanto a tendência de crescimento quanto o padrão sazonal de queda no meio do ano e recuperação no segundo semestre. Observa-se, no entanto, uma divergência crescente a partir de setembro de 2025, quando a série real apresenta aceleração abrupta que o modelo não consegue antecipar integralmente, resultando em superestimativa nos meses finais da janela de teste.

4 Discussão Técnica

4.1 Análise de *Overfitting*

A comparação entre o desempenho no conjunto de treinamento e no conjunto de teste revela padrões marcantes de sobreajuste nos modelos de aprendizado de máquina, conforme evidenciado pela Tabela 3.

Tabela 3: Comparação de desempenho treino vs. teste – análise de *overfitting*.

Modelo	RMSE Treino	RMSE Teste	R^2 Treino	R^2 Teste
Decision Tree	12,12	2023,53	0,9999	-1,7125
XGBoost	0,24	782,60	1,0000	0,5943
Random Forest	363,01	1551,89	0,9686	-0,5954
MLP	438,10	1295,52	0,9543	-0,1119

A Árvore de Decisão exibiu o caso mais extremo de sobreajuste: RMSE de treinamento de apenas 12 unidades contra RMSE de teste de 2.023 unidades, com R^2 de treinamento próximo a 1 e R^2 de teste de -1,71. O XGBoost, apesar do RMSE de treinamento praticamente nulo (0,24), conseguiu generalizar razoavelmente para o conjunto de teste, possivelmente devido ao mecanismo de regularização intrínseco ao algoritmo. O Random Forest e o MLP também apresentaram degradação expressiva entre treino e teste. Estes resultados são consistentes com o tamanho limitado do conjunto de treinamento (79 observações), insuficiente para que modelos de alta capacidade aprendam representações verdadeiramente generalizáveis.

4.2 Capacidade de Capturar Tendência e Sazonalidade

O desempenho superior do SARIMA está diretamente relacionado à sua estrutura paramétrica, que foi construída para capturar explicitamente os componentes identificados na análise exploratória. O parâmetro de diferenciação sazonal $D = 1$ com período $s = 6$ permite ao modelo remover a sazonalidade semestral da série, enquanto os termos autorregressivos e de média móvel, tanto ordinários quanto sazonais, capturam as dependências temporais remanescentes.

O ARIMA puro, por sua vez, obteve o pior desempenho entre todos os modelos (RMSE = 3181,96, $R^2 = -5,71$), evidenciando que ignorar a componente sazonal é uma omissão crítica para esta série. A diferença de AIC entre o ARIMA (1, 1, 3) e o SARIMA (2, 1, 2)(1, 1, 1)₆ - de 1344,45 para 1040,64 - já sinalizava, durante a fase de seleção de modelos, que a estrutura sazonal deveria ser formalmente incorporada.

Os modelos de aprendizado de máquina, por sua vez, dependem das *features* de *lag* para capturar indiretamente a dinâmica temporal. Embora o LSTM seja teoricamente mais adequado para séries com dependências de longo prazo, o tamanho reduzido do conjunto de dados limita sua capacidade de aprendizado, resultando em RMSE de teste de 958 unidades - superior ao SARIMA, porém melhor que os demais modelos de ML.

4.3 Limitações do Estudo

Este trabalho apresenta algumas limitações que devem ser consideradas na interpretação dos resultados. Primeiramente, o caráter univariado da modelagem exclui variáveis exógenas potencialmente relevantes, volatilidade da política tarifária estadual ou mudanças regulatórias da ANEEL. Em segundo lugar, o conjunto de treinamento de 79 observações é modesto para modelos baseados em redes neurais, que tipicamente requerem centenas ou milhares de amostras para uma boa generalização. Por fim, a aceleração observada no final da série sugere que a dinâmica recente pode ser estruturalmente diferente do padrão histórico, o que torna a extrapolação futura intrinsecamente incerta.

5 Conclusão

Este trabalho apresentou uma comparação abrangente de sete modelos de previsão - ARIMA, SARIMA, Árvore de Decisão, Random Forest, XGBoost, MLP e LSTM - aplicados à série temporal de Unidades Geradoras do parque elétrico brasileiro, seguindo o pipeline metodológico completo estabelecido pela disciplina.

O modelo SARIMA(2, 1, 2)(1, 1, 1)₆ foi identificado como o melhor, com RMSE = 538,07, MAPE = 5,98% e $R^2 = 0,8082$ no conjunto de teste. Este resultado destaca a vantagem dos modelos estatísticos clássicos em cenários com séries de tamanho moderado, forte sazonalidade identificável e tendência estrutural bem caracterizada. O XGBoost, segundo colocado, demonstrou capacidade razoável de generalização apesar do sobreajuste no treinamento, enquanto os demais modelos de aprendizado de máquina foram prejudicados pelo tamanho limitado do conjunto de dados.

Entre as limitações identificadas, destacam-se o caráter univariado da análise, o tamanho reduzido do conjunto de treinamento e a impossibilidade de capturar choques exógenos que influenciam a expansão da geração distribuída. Para trabalhos futuros, recomenda-se a incorporação de variáveis exógenas relevantes, como Unidades Consumidoras e Potência Instalada; a expansão do horizonte histórico da série à medida que novos dados se tornem disponíveis; a realização de otimização sistemática de hiperparâmetros para os modelos de ML e DL; e o uso de estratégias de validação cruzada temporal (*walk-forward validation*) ou impletação de *times series split* para uma avaliação mais robusta da capacidade preditiva dos modelos.

Reprodutibilidade

Os experimentos realizados neste trabalho podem ser reproduzidos a partir do notebook disponibilizado no Google Colab [4] e a base de dados utilizada na pasta do Drive [5]. O código-fonte completo, bem como os arquivos utilizados no processamento dos dados, encontram-se disponíveis no repositório público do projeto no GitHub [6].

Referências

- [1] AGÊNCIA NACIONAL DE ENERGIA ELÉTRICA (ANEEL). *Dados abertos – Unidades Geradoras*. Disponível em: <https://dadosabertos.aneel.gov.br>. Acesso em: março de 2026.
- [2] HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: Principles and Practice*. 3. ed. Melbourne: OTexts, 2021. Disponível em: <https://otexts.com/fpp3>.
- [3] CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, p. 785–794.
- [4] BARBOSA, J. P. C.; MELO, L. E. A. *Notebook de previsão de séries temporais*. Google Colab, 2026. Disponível em: https://colab.research.google.com/drive/1_XjPf16zBALvai6bXFhw6Whi5MZYox9N?usp=sharing.
- [5] BARBOSA, J. P. C.; MELO, L. E. A. *Base de dados das Unidades Geradoras de Geração Distribuída do Piauí*. Google Drive, 2026. Disponível em: <https://drive.google.com/drive/folders/1VXE5SgKowGQnGdvS8ykXA46XsMqc09R9?usp=sharing>.
- [6] BARBOSA, J. P. C.; MELO, L. E. A. *Forecast UGs – Time Series Forecasting Project*. GitHub, 2026. Disponível em: https://github.com/barbosajpc/forecast_ugs.